

جامعة تشرين

كلية الهندسة المعلوماتية

قسم الذكاء الصناعي

الجمهورية العربية السورية

وزارة التعليم العالي والبحث العلمي

جامعة تشرين - كلية الهندسة المعلوماتية

قسم الذكاء الصناعي



الكشف عن الوجه ولوحة الترخيص والتعرف عليهم

## Face and License Plate Detection and Recognition

مشروع فصلي

إعداد الطلاب

غنى بركات

جوى علوش

سارة حريقة

إشراف

أ.علاء جراد

بشكل عام بشكل عام ، تحدد سياسة القانون العام لحماية البيانات (GDPR) كيفية الحماية لخصوصية معلوماتك الشخصية. عندما تقوم بتزويد شركة أو طرف معين بمعلوماتك الشخصية ، فيجب احترام خصوصية وحقوق الأفراد في التحكم في البيانات الشخصية الخاصة. ومن المفروض أن تكون البيانات محمية ولن يتم تمريرها إلى أي طرف ثالث، وهنا نتحدث عن معلومات شخصية حساسة مثل صورة فيها لوحة الترخيص الخاصة بسيارة أحد الأشخاص أو صورة يظهر فيها وجهه حيث يتم استخدام هذه المعلومات لضمان أمن ورفاهية الأشخاص، وكان ذلك من خلال تطبيق قانون GDPR الصادر عن الاتحاد الأوروبي لمنح المواطنين القدرة على التحكم في بياناتهم الشخصية. يمكننا تحقيق هذه السياسة بعملية تحديد الوجه ولوحة الترخيص من خلال HOG Detector الذي يستخدم بشكل خاص لمعالجة الصور بغرض تحديد أو اكتشاف الأشياء، بالإضافة إلى معمارية State Of Art-VGG16 التي تستخدم خوارزميات حديثة لتطور وتسرع من عملية اكتشاف وتحديد الكائنات .

أما بالنسبة لكيفية التعامل مع البيانات كمهمة تصنيف الصور-والتي تعد مهمة رئيسية في مشروعنا- قمنا بتوظيف مفهوم ال Transfer Learning مع الVGG16 والذي يصنف الصور إلى فئات محددة. وفي النهاية اذا تم تصنيف ما حددته الشبكات العصبونية إلى وجه أو لوحة ترخيص يتم طمس هذه البيانات من معالم وجه أو أرقام لوحة الترخيص وبهذا نكون قد استخدمنا الذكاء الاصطناعي بما ينفع مصلحة الإنسان من خلال الحفاظ على خصوصيته واحترامها.

# Abstract

---

In general, the GDPR policy sets out how we protect the privacy of your personal information. When you provide your personal information to a company or a specific party, you must respect the privacy and rights of individuals to control their private personal data. The data should be protected and not shared with third parties, and we are talking about sensitive personal information such as an image of a person's car number plate or an image showing their face, as this information is used to ensure people's safety and wellbeing, and this was done by applying the EU GDPR law to give citizens control over their personal data. We can achieve this policy with the process of identifying the face and the number plate through the HOG detector, which is specifically used to process images for the purpose of identifying or detecting objects, in addition to the state-of-the-art VGG16 architecture, which uses modern algorithms to develop and accelerate the process of detecting and identifying objects.

As for how to deal with the data as an image classification task - which is a major task in our project - we used the concept of transfer learning with VGG16, which classifies images into specific categories. In the end, if what the neural network have identified is classified as a face or a number plate, then this data is erased from the features of the face or the numbers of the number plate. In this way, we have used artificial intelligence to serve the interests of people by preserving and respecting their privacy.

|    |                                    |
|----|------------------------------------|
| 3  | 1-الفصل الأول: مقدمة:              |
| 3  | 1-1 الدراسات المرجعية              |
| 4  | 2-1 البيئة والأدوات المستخدمة      |
| 4  | 3-1 منهجية البحث                   |
| 5  | 2-الفصل الثاني:الفصل النظري:       |
| 5  | 1-2 الرؤية الحاسوبية               |
| 5  | 1-1-2 تعريف                        |
| 7  | 2-2 VGG16                          |
| 7  | 1-2-2 تعريف                        |
| 7  | 3-2 Object Detection               |
| 7  | 1-3-2 تعريف                        |
| 8  | 2-3-2 Traditional object detection |
| 8  | 1-2-3-2 HOG Detector               |
| 10 | 3-3-2 نموذج تحديد الكائنات SSD     |
| 10 | 4-2 خوارزمية التحسين آدم Adam      |
| 10 | 1-4-2 تعريف                        |

|    |                                                   |
|----|---------------------------------------------------|
| 11 | ..... 2-4-2 مزايا خوارزمية التحسين آدم            |
| 11 | ..... 3-4-2 الآلية الأساسية لخوارزمية التحسين آدم |
| 13 | ..... 5-2 التعلم المتنقل                          |
| 14 | ..... 6-2 التعلم المتنقل مع VGG16                 |
| 16 | ..... 3-الفصل الثالث: الفصل العملي                |
| 16 | ..... 1-3 المخطط العام للبحث                      |
| 16 | ..... 2-3 المكتبات المستخدمة                      |
| 17 | ..... Classifier 3-3                              |
| 17 | ..... Data Processing 1-3-3                       |
| 18 | ..... Neural Network 2-3-3                        |
| 18 | ..... Backbone 1-2-3-3                            |
| 20 | ..... Modified Fully Connected Layers 2-2-3-3     |
| 21 | ..... Training and Testing 3-3-3                  |
| 23 | ..... Object Detector 4-3                         |
| 23 | ..... Image Pyramids 1-4-3                        |
| 25 | ..... Sliding Windows 2-4-3                       |
| 25 | ..... Object Detection Procedure 3-4-3            |
| 29 | ..... التوصيات                                    |

|    |       |                   |
|----|-------|-------------------|
| 30 | ..... | Reference المراجع |
|----|-------|-------------------|

## قائمة الأشكال

|    |           |
|----|-----------|
| 3  | 1-1-1-2   |
| 4  | 1-2-1-2   |
| 5  | 1-1-2-2   |
| 7  | 1-1-2-3-2 |
| 7  | 2-1-2-3-2 |
| 10 | 1-3-4-2   |
| 12 | 1-5-2     |
| 14 | 1-1-3     |
| 18 | 1-1-2-3-3 |
| 20 | 1-3-3-3   |
| 27 | 1-3-4-3   |
| 27 | 2-3-4-3   |
| 28 | 3-3-4-3   |

---

|          |                                    |
|----------|------------------------------------|
| AdaBoost | Adaptive Boosting                  |
| AdaGrad  | Adaptive Gradient                  |
| ADAM     | Adaptive Moment Estimation         |
| CNN      | Convolutional Neural Network       |
| GDPR     | General Data Protection Regulation |
| HOG      | Histogram of Oriented Gradient     |
| IoU      | Intersection over Union            |
| NMS      | Non-Maximal Suppression            |
| RMSProp  | Root Mean Squared Propagation      |
| ROI      | Region Of Interest                 |
| SGD      | Stochastic Gradient Descent        |
| SSD      | Single Shot-MultiBox Detector      |
| SVM      | Support Vector Machines            |
| VGG16    | Visual Geometry Group              |

## 1- الفصل الأول : مقدمة

أصبح الذكاء الاصطناعي تقنية تحويلية في عالمنا الحديث ، مع العديد من التطبيقات في مختلف الصناعات .

إن التقدم الذي تم إحرازه في الذكاء الاصطناعي ، لا سيما في المناهج القائمة على التعلم العميق ، قد مكّن من تطوير نماذج يمكنها تحقيق أداء متطور في مختلف المهام ، بناءً على ذلك ظهرت الشبكات العصبية التي هي خوارزمية قوية للتعلم الآلي تم تصميمها على غرار بنية ووظيفة الدماغ البشري .

هناك عدة أنواع من الشبكات العصبية ، لكل منها نقاط قوتها وضعفها. يتم تدريب الشبكات العصبية باستخدام backpropagation ، ولها العديد من التطبيقات في مختلف الصناعات ، بما في ذلك التعرف على الصور والفيديو ، والتعرف على الكلام ، ومعالجة اللغة الطبيعية ، والروبوتات .

أما بالنسبة لتطبيقات الذكاء الاصطناعي نأتي على ذكر أهمها وهي الرؤية الحاسوبية التي تعمل على تمكين الآلات من تفسير وفهم البيانات المرئية من العالم من حولنا، تتضمن تطوير الخوارزميات والتقنيات التي تمكن أجهزة الحاسوب من استخراج معلومات ذات مغزى من الصور ومقاطع الفيديو ، مثل التعرف على الأشياء والتعرف على الوجه وفهم المشهد.

وفي هذا المشروع سنقوم بتصميم نظام يستخدم تقنيات التعلم العميق ومعالجة الصور لتحديد الوجوه ولوحات السيارات في كاميرات المراقبة المثبتة في الأماكن العامة مع مراعاة القوانين والقواعد التي تتعلق بالخصوصية و بشأن حماية الأفراد فيما يتعلق بمعالجة البيانات الشخصية وبشأن حرية حركة تلك البيانات وذلك من خلال قانون GDPR، وسيعتمد هذا النظام بشكل أساسي على الخوارزميات الذكية وتقنيات الشبكة العصبية العميقة (Deep Neural Networks) لتحليل الصور وتحديد الوجوه ولوحات السيارات بدقة عالية.

### 1-1 الدراسات المرجعية :

تعتمد نماذج اكتشاف الكائنات التقليدية عادةً على ميزات مصنوعة يدوياً وتستخدم خوارزميات التعلم الآلي للتصنيف والتوطين. تتضمن بعض الطرق البارزة ما يلي:

فيولا-جونز: قدمت خوارزمية Viola-Jones مفهوم الميزات المشابهة ل Haar وخوارزمية AdaBoost. لقد حقق اكتشافاً في الوقت الفعلي للأشياء عن طريق المسح الفعال لهرم الصورة واستخدام المصنفات

المتتالية. على الرغم من فعاليتها في اكتشاف الوجوه والأشياء البسيطة ، إلا أنها تكافح مع المشاهد المعقدة وتغيرات الحجم.

الرسم البياني للتدرجات الموجهة (HOG) يستخرج HOG تدرجات الصورة المحلية ويمثلها كرسم بياني ، والتقاط معلومات الشكل والحافة. توفر هذه الطريقة ، جنبًا إلى جنب مع مصنفات SVM ، دقة جيدة لاكتشاف المشاة. ومع ذلك ، فإنه يكافح مع انسداد الكائن والخلفيات غير الواضحة.

في الختام ، شهد اكتشاف الأشياء والتعرف عليها تطورات كبيرة في السنوات الأخيرة. لقد أثبتت المصنفات المتتالية فعاليتها في اكتشاف الوجوه والأشياء البسيطة ، لكنها تكافح مع المشاهد المعقدة واختلافات الحجم. أظهرت طريقة الرسم البياني للتدرجات الموجهة (HOG) ، جنبًا إلى جنب مع مصنفات SVM ، دقة جيدة في اكتشاف المشاة. ومع ذلك ، فإنه يواجه تحديات مع انسداد الكائن والخلفيات غير الواضحة. بشكل عام ، هناك حاجة إلى مزيد من البحث والتطوير لمعالجة هذه القيود وتحسين أداء خوارزميات اكتشاف الكائنات والتعرف عليها.

## 1-2 البيئة والأدوات المستخدمة :

تم استخدام مجموعات الصور :

- 1-WIDER FACE dataset
- 2- CelebA dataset
- 3- Chinese City Parking Dataset

أما بالنسبة لنوع الشبكة فهي VGG16، التدريب سيتم باستخدام لغة بايثون بالاستفادة من مكتبات اللغة (Pytorch, OpenCV, imutils...). بيئة التدريب المستخدمة هي بيئة مقدمة من شركة غوغل تدعى (Google colab) ، وسيتم الحديث والشرح باستفاضة عن كل منها.

**1-3 منهجية البحث :** تم الاعتماد على العديد من الأوراق البحثية بداية، ثم العديد من الكتب ذات الصلة بالموضوع إضافة للاطلاع على العديد من الأكواد للاستفادة منها في بعض الجزئيات.


## 2- الفصل الثاني : الفصل النظري

### 1-2 الرؤية الحاسوبية :

#### 1-1-2 تعريف :

الرؤية الحاسوبية هي أحد مجالات الذكاء الاصطناعي وعلوم الحاسوب تركز على تمكين الآلات من تفسير وفهم وتحليل الصور ومقاطع الفيديو الرقمية ، على غرار الطريقة التي يقوم بها البشر .

تتضمن رؤية الكمبيوتر استخدام تقنيات وخوارزميات مختلفة لاستخراج معلومات مفيدة من الصور ومقاطع الفيديو الرقمية. تتضمن هذه التقنيات معالجة الصور والتعرف على الأنماط والتعلم الآلي والتعلم العميق..



الشكل رقم (1-1-2)

تقنيات الرؤية الحاسوبية

الرؤية الحاسوبية لها العديد من التطبيقات العملية في مختلف الصناعات ، بما في ذلك الرعاية الصحية والسيارات والتصنيع والأمن والترفيه. بشكل عام ، تعد الرؤية الحاسوبية مجالاً مهماً للبحث والتطوير مع إمكانية إحداث ثورة في العديد من الصناعات وتحسين حياتنا اليومية.



الشكل رقم (1-2-1-2)

التعرف على الكائنات وتحديد الأنماط بواسطة الرؤية الحاسوبية


## 2-2 VGG16 :

### 1-2-2 تعريف :

عبارة عن بنية شبكة عصبية تلافيفية عميقة لتصنيف الصور. تم تطويره من قبل مجموعة الهندسة المرئية في جامعة أكسفورد وكان جزءًا من تحدي التعرف البصري على نطاق واسع على ImageNet (ILSVRC) في عام 2014.

تتكون بنية VGG16 من 16 طبقة ، بما في ذلك 13 طبقة تلافيفية و 3 طبقات متصلة بالكامل. تستخدم الطبقات التلافيفية مرشحات  $3 \times 3$  بخطوة 1 وحشوة من 1 للحفاظ على الأبعاد المكانية للصورة المدخلة. تستخدم طبقات التجميع مرشحات  $2 \times 2$  بخطوة 2 لتقليل الأبعاد المكانية وزيادة المجال الاستقبالي للشبكة.

تم استخدام VGG16 على نطاق واسع كنموذج مرجعي في مهام رؤية الكمبيوتر وألهم المزيد من التطورات في هذا المجال. جعلت بنيته وأدائه خيارًا شائعًا لمهام مثل تصنيف الصور واكتشاف الكائنات وتجزئة الصور.



الشكل رقم (1-1-2-2)  
بنية VGG16

## 3-2 Object Detection:

### 1-3-2 تعريف :

هي تقنية من تقنيات الرؤية الحاسوبية التي تسمح لنا بتحديد نوع وموقع الأشياء في صورة أو فيديو. يمكن لهذه التقنية عدّ مجموع الأشياء في مشهد معين وتحديد مواقعها بدقة.

يُخلط في بعض الأحيان بين الكشف عن الأغراض وتصنيف الصور classification image لذلك سوف نوضح الفرق بين هاتين العمليتين بشكل مختصر.

في تصنيف الصور يتم تصنيف صورة معينة ضمن أصناف مجدولة مسبقاً. حيث تمثل الصورة دخل العملية، ويمثل الخرج اسم العنصر الموجود في الصورة. فمثلاً إذا كان الدخل صورة تحتوي على قطة سيكون الخرج كلمة " قطة " وإذا كان الدخل صورة تحتوي على قطتين سوف يكون الخرج أيضاً " قطة ". من ذلك يمكننا أن نستنتج أن عملية تصنيف الصور رغم أهميتها فهي محدودة بالنتائج التي تعطينا إياها. عكس ذلك في عملية الكشف عن الأغراض حيث يتم تحديد كل عنصر من العناصر المكتشفة ضمن إطار، إضافة إلى

ذلك يتم تحديد موقع هذا العنصر في المشهد المُعطى. من هذا نستنتج أن التعرف على الأغراض هي عملية أعقد من تصنيف الصور وتعطينا معلومات أكثر عن الصورة وبالتالي يمكننا الاستفادة منها بشكل أكبر.

### **:Traditional object detection 2-3-2**

تقدمت الرؤية الحاسوبية بشكل كبير ولكنها لا تزال تواجه تحديا في مطابقة دقة الإدراك البشري. ومع ذلك ، من الجيد دائما أن نرى إلى أي مدى وصلنا. إن مهمة اكتشاف عدد غير معروف من الكائنات الفردية داخل الصورة والتعرف عليها ، والتي تسمى اكتشاف الكائنات ، والتي كانت تعتبر مشكلة صعبة للغاية قبل بضع سنوات فقط ، أصبحت الآن ممكنة وقد تم إنتاجها من قبل شركات مثل Google و IBM.


سنراجع تاريخ اكتشاف الكائنات في "فترة اكتشاف الكائنات التقليدية (قبل عام 2014)"

وبالعودة إلى الوراء 20 عاما، سنشهد "حكمة عصر الأسلحة الباردة". نظرا لعدم وجود تمثيل فعال للصورة في ذلك الوقت ، تم بناء معظم خوارزميات اكتشاف الكائنات المبكرة بناء على ميزات مصنوعة يدويا.

### **: HOG Detector 1-2-3-2**

يعمل كاشف HOG عن طريق استخراج ميزات HOG من صورة معينة أو منطقة اهتمام. تلتقط هذه الميزات الشكل المحلي ومعلومات النسيج عن طريق حساب حجم التدرج والاتجاه داخل الخلايا الصغيرة. يتم بعد ذلك تجميع الرسوم البيانية للتدرجات الموجهة من هذه الخلايا لتشكيل ناقل ميزة.


يشير كاشف HOG ، أو كاشف الكائن المستند إلى HOG ، إلى نظام يستخدم خوارزمية الرسم البياني للتدرجات الموجهة (HOG) لاكتشاف الأشياء. يستخدم كاشف HOG بشكل شائع في تطبيقات رؤية الكمبيوتر لتحديد وتحديد الكائنات داخل الصور أو إطارات الفيديو.



الشكل رقم (2-3-2-1-1)

"هرم الصورة" تمثيل متعدد المقاييس للصورة

يمكن تخصيص خوارزمية HOG عن طريق ضبط المعلمات مثل حجم الخلية وحجم الكتلة وعدد صناديق التوجيه وطريقة التطبيق. يمكن ضبط هذه المعلمات بناءً على المتطلبات المحددة للتطبيق وخصائص الكائنات التي يتم اكتشافها.



الشكل رقم (2-3-2-1-2) HOG Detector

## 2-3-3 نموذج تحديد الكائنات SSD – Single Shot Multi-box Detector:

المحددات من نوع stage-one حيث أن SSD ينتمي إلى هذه العائلة من المحددات و تتكون بنية SSD من الأقسام التالية:

1. شبكة القاعدة Base Network.

2. طبقات إضافية متعددة الامتداد/القياسات Extra Layers with different scales.

3. طبقة التحديد Detection Layer.

SSD هي طريقة اكتشاف كائن أحادية المرحلة تحدد مساحة الإخراج للمربعات المحيطة في مجموعة من المربعات الافتراضية على نسب عرض إلى ارتفاع مختلفة ومقاييس لكل موقع خريطة معلم. في وقت التنبؤ ، تنشئ الشبكة درجات لوجود كل فئة كائن في كل مربع افتراضي وتنتج تعديلات على المربع لمطابقة شكل الكائن بشكل أفضل. بالإضافة إلى ذلك ، تجمع الشبكة التنبؤات من خرائط معالم متعددة بدرجات دقة مختلفة للتعامل بشكل طبيعي مع الكائنات ذات الأحجام المختلفة.

يأتي التحسين الأساسي في السرعة من التخلص من مقترحات الصندوق المحيط والباكسل اللاحقة أو مرحلة إعادة تشكيل الميزة. تشمل التحسينات على الطرق المتنافسة أحادية المرحلة استخدام مرشح تلافيفي صغير للتنبؤ بفئات الكائنات والإزاحات في مواقع الصندوق المحيط ، باستخدام تنبؤات منفصلة (مرشحات) لاكتشافات نسبة العرض إلى الارتفاع المختلفة ، وتطبيق هذه المرشحات على خرائط معالم متعددة من المراحل اللاحقة من a من أجل إجراء الكشف على مستويات متعددة.

## 2-4 خوارزمية التحسين آدم Adam :

### 2-4-1 تعريف:

وهي خوارزمية تحسين من الدرجة الأولى يمكن أن تحل محل عملية انحدار المشتق العشوائي التقليدية SGD “حيث تقوم عملية انحدار المشتق العشوائي بالإنطلاق من نقطة عشوائية وتعمل على الانتقال بخطوات ثابتة

للوصول إلى لحظة التدرّب ولكنّ ذلك يتطلّب عدداً كبيراً من التكرارات بسبب العشوائية، ويمكنها تحديث أوزان الشبكة العصبونية بشكل متكرّر بناءً على بيانات التدريب.


## 2-4-2 مزايا خوارزمية التحسين آدم :

- ذاكرة أقل.
- حسابات فعّالة.
- ثبات التدرّج من خلال عملية تصحيح  $mt$  و  $Vt$  لجعل القيم متقاربة "تم ذكر عملية التصحيح في تهيئة الخوارزمية".
- مناسبة لحل مشاكل التحسين مع البيانات والمعاملات واسعة النطاق.
- مناسبة للأهداف الثابتة (أي بيانات التعلّم ثابتة ولا يتم تحديثها ضمن عملية التعلّم، مثلاً: عملية تصنيف الصور).
- مناسبة للمشاكل ذات الضوضاء العالية أو التدرجات المتفرّقة.
- تتطلّب القليل من الضبط للمعاملات الأساسية.

## 2-4-3 الآلية الأساسية لخوارزمية التحسين آدم:

تختلف خوارزمية آدم عن انحدار المشتقّ العشوائيّ SGD ، حيث يُحافظ الأخير على مُعامل تعلّم واحد ألفا ( $\alpha$ ) لتحديث جميع الأوزان، ولا يتغيّر معدّل التعلّم أثناء عملية التدريب. وفي الجّهة المقابلة تقوم آدم بحساب معدّلات التعلّم التكيّفية المستقلّة للمعاملات المختلفة عن طريق حساب تقديرات اللحظة الأولى والثانية للتدرّج "حسابات خاصّة لهذه الخوارزمية".

ولقد حصلت خوارزمية آدم على مزايا خوارزميتي "آدا جراد AdaGrad و آر إم إس بروب RMSProp و مومنتوم Momentum " في نفس الوقت



الشكل رقم (1-3-4-2)

شجرة إيجاد خوارزميات التعلم بحسب التحسينات المضافة للخوارزمية الأصل

حيث تتمثل خوارزمية التدرج التكيفي (AdaGrad=Adaptive Gradient) في ضبط المعاملات المناسبة لمعدل التعلم، لإجراء تحديثات كبيرة لمعاملات متفرقة وتحديثات صغيرة للمعاملات المتكررة ففي كل خطوة زمنية  $t$ ، تحدّد هذه الخوارزمية معدّلاً مختلفاً للتعلم لكل معامل تيتا " $\theta$ " وتحديث المعاملات المقابلة ثم تقوم بإجراء التدريب وهي مناسبة لمعالجة البيانات المتفرقة لكن المشكلة تكمن في بعض الحالات حيث أنّ معدل التعلم سينخفض بسبب تراكم التدرجات من بداية التدريب وأنّ هنالك نقطة لن يتعلمها النموذج مرة أخرى لأنّ معدل التعلم يكاد أن يكون صفراً، عملت على حلها خوارزمية آدم بجعل معدل التعلم يتّجه نحو الاستقرار.

أما خوارزمية (RMSProp=Root Mean Square Propagation) آر إم إس بروب (جذر متوسط مربع الانتشار)، هي اشتقاق من خوارزمية التدرج التكيفي "آدا جراد" فهي تعتمد على تقسيم معدل التعلم للوزن على المتوسط الحالي لقيم التدرجات الحديثة لهذا الوزن، وتحافظ على معدل التعلم لكل مُعاملة تعتمد

في حسابها عليه (أي معدل التعلم الإجمالي فيها ثابت تقريباً)، لكنها تحسب التدرّج بمتوسط الإنحدار بشكل أسّي بدلاً من مجموع تدرجاته، لذا تتكيف وتلبي معدلات التعلم المحددة المتغيرة تلقائياً لمنع معدل التعلم الإجمالي للنموذج من الابتعاد عن الحافة والارتداد وهذا يعني أن الخوارزمية تتمتع بأداء ممتاز في المشكلات غير المستقرة.


## 5-2 التعلم المتنقل Transfer Learning :

التعلم المتنقل أو التعلم بالنقل هو أسلوب تعلم آلي يتضمن أخذ نموذج مدرب مسبقاً واستخدامه كنقطة انطلاق لتدريب نموذج جديد على مهمة مختلفة ولكنها ذات صلة. في التعلم بالنقل ، يكون النموذج المدرب مسبقاً عبارة عن شبكة عصبية عميقة تم تدريبها على مجموعة بيانات كبيرة لمهمة محددة ، مثل تصنيف الصور.

بدلاً من تدريب نموذج جديد من البداية ، يتضمن نقل التعلم أخذ النموذج المدرب مسبقاً وضبطه على مجموعة بيانات جديدة لمهمة جديدة. الفكرة هي أن النموذج المدرب مسبقاً قد تعلم بالفعل الكثير من الميزات المفيدة من مجموعة البيانات الأصلية ، والتي يمكن الاستفادة منها لتحسين أداء النموذج الجديد في المهمة الجديدة.

هناك طرق مختلفة لأداء التعلم بالنقل ، ولكن أحد الأساليب الشائعة هو استخدام النموذج المدرب مسبقاً كمستخرج للميزات. في هذا النهج ، يتم استخدام النموذج المدرب مسبقاً لاستخراج الميزات من مجموعة البيانات الجديدة ، ثم يتم استخدام هذه الميزات كمدخلات لنموذج جديد تم تدريبه على المهمة الجديدة. يتمتع التعلم الانتقالي بالعديد من المزايا مقارنة بتدريب نموذج جديد من البداية. يمكنه توفير الوقت والموارد الحسابية ، بالإضافة إلى تحسين أداء النموذج الجديد في المهمة الجديدة ، خاصةً إذا كانت مجموعة البيانات الجديدة صغيرة أو مشابهة لمجموعة البيانات الأصلية. يستخدم التعلم الانتقالي على نطاق واسع في مختلف المجالات ، مثل رؤية الكمبيوتر ومعالجة اللغة الطبيعية والتعرف على الكلام.

## Transfer Learning



الشكل رقم (1-5-2)

آلية عمل التعلم الانتقال

### 6-2 التعلم المتنقل مع VGG16:


يعد تعلم النقل باستخدام VGG16 أسلوبًا شائعًا في مهام رؤية الكمبيوتر ، بما في ذلك تصنيف الصور واكتشاف الكائنات والتجزئة VGG16. عبارة عن شبكة عصبية تلافيفية مُدرّبة مسبقًا تم تدريبها على مجموعة بيانات كبيرة من الصور لمهمة تصنيف الصور .

لاستخدام VGG16 لنقل التعلم ، يتم أولاً تحميل النموذج المدرب مسبقًا وتجميد أوزانه. بعد ذلك ، يتم استبدال الطبقة (الطبقات) النهائية من النموذج بطبقات جديدة مصممة خصيصًا للمهمة المحددة في متناول اليد. على سبيل المثال ، في تصنيف الصور ، يتم استبدال الطبقة النهائية بطبقة جديدة لها نفس عدد عقد الإخراج مثل عدد الفئات في مجموعة البيانات الجديدة ، ويتم ضبط النموذج الجديد على مجموعة البيانات الجديدة.

يتضمن الضبط الدقيق للنموذج في مجموعة البيانات الجديدة تدريب الطبقات الجديدة مع الحفاظ على ثبات أوزان الطبقات المدربة مسبقًا. يتيح ذلك للنموذج الاستفادة من الأوزان المدربة مسبقًا لاستخراج ميزات مفيدة من مجموعة البيانات الجديدة ، مع التكيف أيضًا مع الخصائص المحددة لمجموعة البيانات الجديدة.

لقد ثبت أن تعلم النقل باستخدام VGG16 فعال في مهام رؤية الكمبيوتر المختلفة ، بما في ذلك اكتشاف الكائنات وتقسيمها. في هذه المهام ، عادةً ما يتم استخدام نموذج VGG16 المدرب مسبقًا كمستخرج ميزة ، حيث يتم تمرير الصورة عبر شبكة VGG16 لاستخراج الميزات ، ثم تُستخدم هذه الميزات كمدخلات لنموذج جديد يتم تدريبه على مهمة محددة

### 1-3 المخطط العام للبحث :



الشكل رقم (1-1-3)

المخطط العام للبحث

### 2-3 المكتبات المستخدمة :

تم اعتماد مكتبة PyTorch التي تعد مكتبة تعلم الآلي مفتوحة المصدر تعتمد على Torch لمعالجة اللغة الطبيعية باستخدام Python.

إنه مشابه لـ NumPy ولكن مع دعم GPU قوي. يوفر الرسوم البيانية الحسابية الديناميكية التي يمكنك تعديلها أثناء التنقل بمساعدة PyTorch autograd. أيضًا أسرع من بعض الأطر الأخرى.

بالإضافة إلى مكتبة imutils وهي عبارة عن تغليف يعتمد على OpenCV لتحقيق الغرض من استدعاء واجهة OpenCV بشكل أكثر إيجازاً. يمكنه بسهولة تنفيذ سلسلة من العمليات مثل ترجمة الصور ، التدوير ، القياس ، والهيكل العظمي.

### : Classifier 3-3

المصنف هو نوع من الشبكات العصبية التي يمكن تدريبها على تصنيف البيانات إلى فئات محددة ، مثل الصور إلى فئات مختلفة. يمكن تنفيذه باستخدام بنى الشبكات العصبية المختلفة ، مثل الشبكات العصبية التلافيفية (CNNs). عادة ما يأخذ المصنف بيانات الإدخال ، ويعالجها من خلال طبقاته ، ويخرج تسمية فئة متوقعة للإدخال المحدد.

### : Data Processing 1-3-3

بداية نبدأ مع صف ImageFolder هو صف توفره مكتبة PyTorch تستخدم لتحميل مجموعات بيانات ملفات الصور .

يفترض صف ImageFolder أن ملفات الصور منظمة في مجلدات، حيث يمثل كل مجلد فئة و يصنف الصور علي هذا الأساس.

مجموعات البيانات التي تم استخدامها:

المجموعة الأولى faces and non-faces dataset شكلناها من دمج مجموعة صور مأخوذة من:

Wider dataset (مجموعة بيانات WIDER FACE هي مجموعة بيانات معيارية لاكتشاف الوجه)

Caltech dataset (مجموعة بيانات واسعة تستخدم لتمييز 256 صف من الكائنات (قوارب, نمل,

هواتف...).

المجموعة الثانية license plates dataset هي دمج جزء من مجموعة البيانات الضخمة CCPD2019 (هي مجموعة بيانات لاكتشاف لوحة الترخيص والتعرف عليها وتحتوي على أكثر من 250 ألف صورة فريدة للسيارات) و Caltech dataset.

عرفنا صف Faces\_dataset يرث الصف ImageFolder وتم تهيئته ب dictionary يمرر إليه اسم المجلدات و label لكل مجلد.

حيث استخدمنا التابع loader في الطريقة getItem والتي يوفرها الصف ImageFolder للتعامل من الصور ضمن المجلدات.

وظفنا الصف Transforms مع التوابع التي يوفرها مثل:

- CenterCrop و Resize لنلائم دخل ال vgg16 (224×224)
- بالإضافة لتابع Normalize الذي يجعل القيم تتراوح ضمن مجال محدد مما يجعل عملية التدريب أكثر كفاءة من خلال إزالة التحيز الناتج عن القيم الصغيرة او الكبيرة وايضاً تسهيل عمليات المقارنة والتصنيف وتقليل تأثير القيم المتطرفة.
- Grayscale: يقوم هذا التابع بتعديل على ألوان الصورة لتصبح رمادية مما يمنع الشبكة من حفظ الأمثلة التدريبية.
- random\_erasing: إخفاء جزء من الصورة لمنع مشكلة زيادة الملائمة.

قسمنا البيانات إلى مجموعتين Training data بنسبة 75% و Testing data بنسبة 25% باستخدام التابع random\_split الذي توفره مكتبة torch حيث يقوم بتقسيم مجموعة بيانات عشوائياً إلى مجموعتين فرعيتين أو أكثر بنسبة محددة وذلك من أجل كلتا المجموعتين.

### 2-3-3 : Neural Network

قمنا بتعريف class modified\_VGG16 وتمت تهيئته ب models.vgg16 المدربة مسبقاً على ImageNet و المتوفرة ضمن torch حيث استخدمنا منها الطبقات الالتقافية فقط ك backbone لتكون المسؤولة عن استخراج ميزات الأصناف المسؤولة عن استخراج ميزات الأصناف.

### 1-2-3-3 : Backbone

آلية عمل VGG16:

-input image: الإدخال إلى VGG16 عبارة عن صورة RGB بحجم  $224 \times 224$  بكسل.

-Convolutional layers: يتم تمرير صورة الإدخال عبر سلسلة من الطبقات التلافيفية ، حيث تطبق كل طبقة مجموعة من المرشحات القابلة للتعلم على صورة الإدخال. ناتج كل طبقة تلافيفية عبارة عن مجموعة من خرائط المعالم التي تلتقط جوانب مختلفة من الصورة المدخلة

-pooling layers:

بعد كل طبقة تلافيفية ، يتم تطبيق طبقة تجميع لتقليل الأبعاد المكانية لخرائط المعالم وزيادة المجال الاستقبالي للشبكة. يستخدم VGG16 أقصى تجمع مع مرشح  $2 \times 2$  وخطوة 2.

-fully connected layers:

يتم تسطیح ناتج آخر طبقة تجميع وتمريرها عبر سلسلة من الطبقات المتصلة بالكامل من أجل التصنيف. تحتوي الطبقات المتصلة بالكامل على عدد كبير من المعلمات القابلة للتعلم ويتم تدريبها على تصنيف صورة الإدخال إلى إحدى الفئات المحددة مسبقًا.


-Softmax activation:

يتم تمرير إخراج آخر طبقة متصلة بالكامل من خلال وظيفة SoftMax activation ، والتي تعمل على تطبيع المخرجات وتنتج توزيعًا احتماليًا على الفئات المحددة مسبقًا.

-Prediction:

يتم اختيار الفئة ذات أعلى احتمالية لتكون الفئة المتوقعة لصورة الإدخال.

بشكل عام ، يعمل VGG16 من خلال تعلم التمثيل الهرمي لصورة الإدخال التي تلتقط مستويات مختلفة من التجريد ، من الميزات منخفضة المستوى مثل الحواف والأنسجة إلى الميزات عالية المستوى مثل الأشكال والكائنات. ثم يتم استخدام هذا التمثيل الهرمي للتصنيف حسب الطبقات المتصلة بالكامل في نهاية الشبكة.



الشكل رقم (1-1-2-3-3)

Vgg16

### :Modified Fully Connected Layers 2-2-3-3

قمنا بالتعديل على fully connected layers حتى نمكن الشبكة العصبونية من تمييز صفيين من الأغراض بدلاً عن ال 1000 صف المدربة عليهم ال VGG16 سابقاً.

(new\_fc\_layer) هي طبقة متسلسلة تتكون من الطبقات الفرعية التالية:

. الطبقة الخطية:

- ميزات الإدخال 512 (in\_features):

- ميزات الإخراج (ميزات\_خارجية): 256

- الانحياز (التحيز): True

. تابع تنشيط ReLU:

- Inplace: True

. طبقة التسرب:

- معدل التسرب (ع): 0.3

- Inplace: false

. الطبقة الخطية:

- ميزات الإدخال 256 (in\_features):

- ميزات الإخراج (ميزات\_خارجية): 128

- الانحياز (التحيز): True

تابع تنشيط ReLU:

- Inplace: True

. طبقة التسرب(dropout):

- معدل التسرب (ع): 0.3

- Inplace: false

. الطبقة الخطية:

- ميزات الإدخال 128 (in\_features):

- ميزات الإخراج (ميزات\_خارجية): 1

- الانحياز (التحيز): true

. وظيفة التنشيط السيني

باختصار، يتكون (new\_fc\_layer) من ثلاث طبقات خطية مع وظائف تنشيط ReLU بينهما ، ويتضمن طبقات التسرب بين الطبقات الخطية. أخيرًا ، يتم استخدام وظيفة التنشيط السيني في الطبقة الأخيرة. يستخدم هذا الهيكل بشكل شائع في نماذج مهام التصنيف الثنائي.

وللحفاظ على الأوزان المدربة سابقاً ضمن ال backbone أنشأنا التعليمية التالية التي تقوم بتجميد تلك الأوزان أي تشير إلى أنها لا يجب أن تحدّث خلال عملية التدريب.

```
for param in self.backbone.parameters():  
    param.requires_grads = False
```

أخذنا نسختين من هذا النموذج بحيث سيتم تدريب النسخة الأولى على مجموعة البيانات الخاصة بالوجوه ليقوم بمهمة تمييز الوجوه، أما النسخة الثانية ستدرب على مجموعة لوحات الترخيص لتقوم بتمييز اللوحات وذلك من أجل استخدام كلا المصنفين ضمن كاشف الأغراض.

### :Training and Testing 3-3-3

عملية التدريب تمت للنسختين بشكل مماثل معاملات التدريب كما يلي:

خوارزمية التحسين: تم اختيار Adam optimizer لما يوفره من تكيف مع مقاييس المعاملات المختلفة واستخدام الأمثل للذاكرة، وحققناه من خلال الوحدة torch.optim و التي تحوي عدة محسنات أخرى.


Learning rate: ضبطنا قيمته على 0.001 حيث ستتقبل خوارزمية التدريب بتحديثه ليلائم المعاملات الفردية.

بينما تم ضبط ال Batch size على 64 وعدد epochs 20 وإضافة طبقات dropout بمعدل 0.3 كما وضحناها في بنية الشبكة العصبونية.

بالنسبة لتابع الخسارة اخترنا Binary Cross Entropy Loss وهو مفيد بشكل خاص في مهام التصنيف الثنائي وحققناها عن طريق nn.BCELoss.

```
optimizer = optim.Adam(plates_model.parameters(), lr=0.001)  
loss_fn = nn.BCELoss()
```

بعد تدريب نسختي النموذج حصلت النسخة الأولى المدربة لتمييز الوجوه على دقة 95% بينما النسخة الثانية حصلت على 96% .



الشكل رقم (1-3-3-3)

نتائج المصنف

### 3 - 4 : Object Detector

سنستخدم في مشروعنا خوارزميات تقليدية في الرؤية الحاسوبية لبناء كاشف الأغراض والتي تعد أساس معظم المعماريات المتقدمة التي تعتمد الـ Deep Learning.

### 3-4-1 : Image Pyramids

هو تمثيل متعدد المقاييس للصورة، يمكننا باستخدامه العثور على الكائنات بأحجام مختلفة في الصور.

من أجل تحقيقه عرفنا تابع image\_pyramid الذي يجب تزويده بالتالي:

الصورة image التي نريد ان نمثلها بعدة مقاييس ثم المقياس scale الذي سيحدد نسبة تصغير الصورة في كل طبقة وأخيراً الحجم الأصغر أي حجم آخر طبقة minSize.

يقوم هذا التابع أولاً بتوليد الصورة الأصلي (الحجم الأصلي) ثم يكرر داخل حلقة while True العملية resize ويولد الصورة الناتجة حتى يصبح حجم الصورة أكبر لل minSize.

حيث استخدمنا التعليمة resize من المكتبة imutils والتي تساعدنا في تحقيق العملية.

### : Sliding Windows 2-4-3

من منظور الرؤية الحاسوبية النافذة المنزلقة هي منطقة مستطيلة ذات عرض وارتفاع ثابت تتحرك عبر الصورة، تلعب النوافذ المنزلقة دوراً أساسياً في تصنيف الكائنات، حيث تسمح لنا بتحديد مكان تواجد الكائن في الصورة بدقة.

بدمج sliding widows و image pyramids معاً يمكننا اكتشاف الكائنات في الصور بمقاييس ومواقع مختلفة.

عرفنا التابع sliding\_windows الذي يأخذ البارامترات التالية:

الصورة image التي نريد ان نمرر عليها النافذة والخطوة step أي عدد البكسلات التي نريد انت نتخطاها عند كل انزلاق وأخيراً لدينا ws وهي حجم النافذة ويذكر أنه يجب ان تكون مساوية ل minSize في تابع image\_pyramid .

يقوم التابع بالالتفاف عن طريق حلقتين متداخلتين على الصورة اعتماداً على حجم النافذة والخطوة ويقوم في كل التفاف بتوليد tuple يحوي الاحداثيات (x,y) التي تمثل الزاوية اليسارية العليا لل ROI بالإضافة إلى ال ROI نفسها.

### : Object Detection Procedure 3-4-3

تعتمد عملية كشف الكائنات باستخدام الـ sliding windows و image pyramids على الخطوة التالية:

من أجل كل قياس في الهرم سوف نمرر نافذة منزقة، وعند كل نافذة سنستخرج الـ ROI، ثم نمررها إلى المصنفات و نقوم باختبار وجود رخصة سيارة أو وجوه لنحسب بعدها الاحتمالات التي تتوافق مع الحد الأدنى لقبولها وأخيراً نطبق خوارزمية الـ Non-maxima suppression على bounding boxes .

بدايةً هيئنا مجموعة من المتغيرات WIDTH من أجل أن نتأكد من إن جميع الصور لها العرض ذاته، وPYR\_SCALE وهو عامل القياس الذي سنعتمد عليه في الهرم، WIN\_STEP وهو الخطوة للنوافذ، وROI\_SIZE والذي يتحكم في نسبة العرض إلى الارتفاع للكائنات التي نريد اكتشافها حيث سنستخدمه في التابعين السابقين.

نهياً قائمتين فارغتين rois وlocs لتخزين ROIs ومواقعها، ثم نبدأ بالمرور على كل قياس بالصورة نحسب معامل التقييس بين الصورة الأصلية والصورة الحالية في الهرم من أجل استعادة أبعاد الـ ROI في الصورة الأصلية، وكما ذكرنا من أجل كل قياس نمر عليها بالنافذة المنزقة ونحسب الأبعاد الحقيقية لنستطيع تخزين المواقع ضمن locs وأيضاً نطبق توابع الـ transforms التي عرفناها سابقاً لتلائم دخل المصنفات ثم نخزنها ضمن القائمة rois.

بعد انتهاء هذه الخطوة نمرر كل ROI ضمن القائمة rois الى المصنفات ونخزن الاحتمالات ضمن قائمتين كل قائمة مسؤولة عن خرج مصنف واحد في نهاية الحلقة كان لدينا القائمتين preds للوجوه و preds\_1 للرخص.

من أجل كل احتمال لـ ROI في القائمة الواحدة يحقق الحد الأدنى نقوم بإضافته مع الموقع المقابل لها في القائمة locs بشكل tuple في قائمة جديدة.

أخيراً نقوم بتنفيذ خوارزمية قمع غير الحد الأقصى (NMS) هو أسلوب معالجة لاحقة يستخدم بشكل شائع في خوارزميات اكتشاف الكائن للتخلص من توقعات الصندوق المحيط الزائدة عن الحاجة أو المتداخلة. والغرض منه هو تحديد المربعات المحيطة الأكثر دقة وتمثيلاً أثناء إزالة عمليات الكشف المكررة.

تتضمن عملية عدم الحد الأقصى للقمع الخطوات التالية:

\_درجات الثقة في الصندوق المحيط: يرتبط كل توقع للمربع المحيط بدرجة الثقة ، والتي تمثل احتمالية وجود الكائن المتوقع داخل المربع.

\_الفرز: يتم فرز المربعات المحيطة بترتيب تنازلي بناءً على درجات الثقة الخاصة بهم. يتم وضع المربع الذي يحتوي على أعلى درجة ثقة في أعلى القائمة

\_التحديد: يتم تحديد المربع المحيط بأعلى درجة ثقة كإكتشاف وإضافته إلى قائمة الاكتشافات النهائية.

\_ حساب التداخل: بدءًا من ثاني أعلى مربع لإحاطة الدرجات ، تقارن الخوارزمية تداخلها مع الاكتشافات المحددة مسبقًا. يتم قياس التداخل عادةً باستخدام مقياس التقاطع فوق الاتحاد (IoU) ، والذي يحسب نسبة منطقة التقاطع بين صندوقين محيطين إلى منطقة الاتحاد الخاصة بهم.

\_ الإلغاء: إذا كان التداخل بين المربع المحيط الحالي وأي من الاكتشافات المحددة سابقًا يتجاوز حدًا معينًا (على سبيل المثال ،  $IoU > 0.5$ ) ، فإن المربع المحيط يعتبر زائدًا عن الحاجة ويتم إلغاؤه. يتم إزالته من قائمة الاكتشافات.

\_ التكرار: تستمر العملية بشكل متكرر ، والانتقال إلى المربع المحيط التالي ذي الدرجة الأعلى وتكرار الخطوتين السابقتين حتى تتم معالجة جميع المربعات المحيطة.

من خلال تطبيق منع غير الحد الأقصى، يتم التخلص من المربعات المحيطة الزائدة التي تمثل نفس الكائن ، ويتم الاحتفاظ فقط بالكشافات الأكثر ثقة وعدم تداخل. يساعد هذا في تحسين دقة وكفاءة خوارزميات اكتشاف الكائنات عن طريق تقليل التوقعات المكررة.

من المهم ملاحظة أن التنفيذ المحدد للقمع غير الأقصى قد يختلف اعتمادًا على خوارزمية اكتشاف الكائن أو إطار العمل المستخدم. يمكن استخدام قيم واستراتيجيات عتبة مختلفة للتعامل مع الصناديق المتداخلة بناءً على متطلبات التطبيق.


نطبق الخوارزمية على محتويات القوائم الناتجة من الخطوة السابقة للحصول على الصناديق الصحيحة لنقم أخيرًا بتنعيم محتواها باستخدام التنعيم الغاوسي من المكتبة OpenCV لتحقيق هدف المشروع .

بتطبيق على الصورة التالية ينتج لدينا ما يلي:




الشكل رقم (1-3-4-3)

صورة الدخل



الشكل رقم (2-3-4-3)

الصورة قبل تطبيق NMS



الشكل رقم (3-3-4-3)  
الصورة بعد تطبيق NMS وتطبيق الطمس

- يمكن تحسين أداء الشبكة العصبونية من خلال تدريبها على مجموعة بيانات أضخم خاصة ب رخص السيارات وايضاً الوجوه لتصبح قادرة على تمييزها بدقة تصنيف أعلى.
- تحسين عملية الانزلاق والهرم عن طريق تعديل حجم النوافذ المنزلقة والهرم من خلال تجربة أحجام مختلفة للنوافذ والهرم للحصول على نتائج بدقة أعلى.
- يمكن تحسين أداء النظام عن طريق تحسين جودة الصور المدخلة عن طريق استخدام تقنيات مثل تنظيف الصور من الضوضاء وتحسين وضوحها وتباينها لتحسين قدرة النظام على استشعار وتمييز الكائنات.

## المراجع Reference

---

• اسم الورقة:

License Plate Detection and Recognition in Unconstrained Scenarios

المؤلفين:

S'ergio Montazzolli Silva and Cl'audio Rosito Jung

الجامعة:

Institute of Informatics - Federal University of Rio Grande do Sul Porto Alegre,  
Brazil

تاريخ النشر: 2018

رابط الورقة:

[http://openaccess.thecvf.com/content\\_ECCV\\_2018/papers/Sergio\\_Silva\\_License\\_Plate\\_Detection\\_ECCV\\_2018\\_paper.pdf](http://openaccess.thecvf.com/content_ECCV_2018/papers/Sergio_Silva_License_Plate_Detection_ECCV_2018_paper.pdf)

• اسم الورقة:

SSD: Single Shot MultiBox Detector

-المؤلفين:

Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed,  
Cheng-Yang Fu, Alexander C. Berg

-الجامعة: Cornell University

-تاريخ النشر: 8 / Dec / 2015

<https://doi.org/10.48550/arXiv.1512.02325>

-رابط الورقة:

• اسم الورقة :

Network for Transfer learning using VGG-16 with Deep Convolutional Neural  
Classifying Images

-المؤلفين: Srikanth Tammina

-الجامعة:

Electrical Engineering, Indian Institute of Technology, Hyderabad

-تاريخ النشر: October / 2019

-رابط الورقة :

<http://dx.doi.org/10.29322/IJSRP.9.10.2019.p9420>

• اسم الورقة :

Very Deep Convolutional Networks for Large-Scale Image Recognition

-المؤلفين :

Karen Simonyan, Andrew Zisserman

-الجامعة: Cornell University

-تاريخ النشر: 4 / sep / 2014

-رابط الورقة:

<https://doi.org/10.48550/arXiv.1409.1556>

• اسم الورقة :

Histograms of Oriented Gradients for Human Detection

-المؤلفين :

Navneet Dalal and Bill Triggs

-الجامعة: INRIA Rhone-Alps

-رابط الورقة:

<http://lear.inrialpes.fr/>

